

第一章 | 为什么要写 Loop

它说做完了

你离开后它继续跑，回来听到「完成」；真正的问题是这句话凭什么可信。

- 你离开了，系统继续工作。
- 你回来，它说：完成。
- 凭什么信？

场景 • 投标书 虚构场景。周五下班前，你让 Agent 起草一份投标书；周一它说「标书完成，可以提交」。你敢盖章吗？

→为什么要把逐轮提示交给系统？

为什么有人开始「写 Loop」

Osmani：用系统接替人逐轮提示 Agent，让系统根据反馈组织下一步。

现在

逐轮提示

看结果



想下一句



再敲给它

每一轮都要你。

想要的

说清目标

说清目标，让它朝那边走；
它自己看出哪里错、自己改；
你把关方向和终点。

Addy Osmani • 2026-06-07：用系统接替人逐轮提示 Agent。

→不是所有决定一次交出，先看两种交接。

今天的路线图：一张阶梯

从基线看起，每交出动手或续跑的决定，就配相应护栏；这是一条教学路线，不是人人必经的等级。

1

基线

说法：你说一句、它做一段、你再说下一句。

2

动手档

说法：先让它动手，但关键步骤你点头。

3

续跑档

说法：你给标准，它自己判断要不要再改一轮。

`/goal`

现在的 coding agent 都支持 `/goal` 命令。

场景 · 投标书 基线：你让它写一章，看完再说下一章。动手档：翻招标文件、写草稿它直接做；报价和上传平台，还要你批。续跑档：你定好「不废标、评分项都有对应」，它自己查、自己改，满足了才停下来找你验收。

更进阶的「定时唤醒」，今天不展开。

→先别急着爬，看看你现在站在哪。

不往上走，不需要理由。

你每说一句，它做一段，你看一眼，再决定下一句。

这就是基线：每一轮由你发起，每一轮由你判断。

留在这里是合理选择，不是失败。

→你看完再纠正，已经在用反馈；它怎样进入下一步？



反馈让 Loop 成立

下一步依据环境或人的反馈决定，才形成反馈循环；固定重跑只是抽卡。



反馈环要你来搭：它怎么发现错，你设计「错」的信号；拿什么对照，你来找例子。

场景 • 投标书 你把评分表拆成逐条自查清单，再找几份往年中标和废标的标书当对照；它交稿前先对一遍，错在哪一眼看得出；每次对照的结果都留成记录，日后接手的人能复查。

Anthropic • 2024-12-19: agent 依靠环境反馈，在循环中使用工具。

→反馈接上了，先看能否让它在授权内自己动手。

交出动手授权

让 Agent 在授权范围内动手，省掉的是逐条打断，不是结果判断。

允许直行

低风险动作，直接完成。

沙箱内跑

限定范围内执行，不越界。

必须人批

涉及外部动作，先由人确认。

硬拒绝

触碰红线，系统直接拦下。

省掉的是逐条点「允许」；每一轮结束，看的还是你。

场景 • 投标书 读招标文件、写草稿可直接做；调用历史标书库限定范围；上传投标平台须人批；改报价与承诺条款直接拒绝。

→这张处置表怎样真正限制执行？

规则要能限制实际执行

告示不是门锁：要的是它做不到，不是它答应过。

告示

提示词里写「请勿修改」

提醒，不是锁。

门锁

把权限拿掉、设好上限

它想越也过不去。

场景 • 投标书 提示词里写「别改报价」，是告示；把改报价的权限拿掉、设好上限，才是门锁。

回去列出你最在意的三条红线，各问一句：Agent 不听话，系统还拦得住吗？拦不住，就只是告示。

锁装好了，再说清每次批准管什么

一次授权，绑定三项边界

一次批准绑定动作、目标范围和有效期；任何一项改变，都要重新批准。

批之前先填三格，一格都不能空。

动作 它能做什么，不能做什么 批准之前先写清	范围 它能碰哪些东西 范围之外一律不碰	有效期 批准管到什么时候 到期自动作废
---	--	--

三格任何一格变了——想多做一件事、想碰新的东西、过了有效期——就重新批。

场景 · 投标书 动作：只许起草，不许改报价、不许发出。范围：只限技术部分，仅内部使用。有效期：到投标截止前，截止后授权自动作废。想改报价、想发给合作方、过了截止时间——就重新批。

→批准的只是动手。每一轮要不要继续，仍由你决定。再交出这个决定，门票就贵了。

第四章 | 续跑之前，先配判据

下一级的门票贵了

交出续跑权，是让系统按约定条件决定是否再开一轮。

基线、动手档：每轮之后由人决定是否继续。

续跑档：裁判判约定条件，人仍守验收。

先看票价，再决定爬不爬。

场景 · 投标书 以前每写一章你看一眼再放下一章；周末你不在，谁来决定它要不要继续改下一版？

→门票第一行：把「好」写成机器能对照的句子。



Goal 要写清终态与证明

Goal 要写清可观察终态，以及证明它的检查路径。

/goal 命令里要写的东西——现在的 coding agent 都支持它。

终态

能被看见、能被核对的完成状态。

检查

怎么证明它到了：谁去看、对照什么。

难的不是写，是发现自己脑子里那把尺子。

场景 · 投标书 终态：每个评分项都有对应页，且没有废标项。检查：对照评分表逐条打开标书，核对每项的页码和证明材料。

→光有终态和检查还不够，还要写「不许变的东西」。

约束与兜底

约束写清不能改变什么，无进展出口和资源上限限制无效续跑；系统不能只有目标，没有兜底。

01

约束

写清不许变的东西。

02

出口

没进展就停，交给别人。

03

上限

轮次、时间、资源到边界就停。

场景 · 投标书 约束：不改报价、不动承诺条款。出口：连续两轮没进展就停下交给别人。上限：定好轮数和投标截止时间。

→目标与边界写好了，一轮做完，怎么判下一步？

一轮结束后：继续、停下，还是找你？

只有未达成、可重试且未触出口时才继续；其他状态按原因停止或交人。

这一轮做完了

证据：运行结果、报错、日志

裁判（Eval）对照判据来解释，理由回到下一轮

标准、歧义和验收，由人负责。

继续

继续

未达成、可重试且未触出口 → 带理由继续。

回环：仅当可重试且未触出口

停止候选

停止候选

条件满足 → 停止候选，仍待验收。

暂停，不是已验收

交人

停并交人

不可能或无法判定 → 停并交人。

分别记录原因

场景 • 投标书 继续：缺业绩证明，补写后再查。停止候选：评分项都有对应页，停下等你签。停并交人：资质证明拿不到（不可能）；核对超时（无法判定）。

→规则写在那里，实际执行真的经过它吗？



检查要真的经过，也要真的拦得住

有检查，不等于实际执行经过了检查；放手前，还要证明它真能拒绝错误。

- 1 检查表写了，不等于它真的核对了：条目有，却可能被跳过。
- 2 放手前，先故意放一个已知的错进去：检查拒绝，才说明这一类错能被拦住。
- 3 没拒绝，先修检查，再考虑放手：就像先拿一张假钞试验钞笔，再信它。

场景 · 投标书 检查表里有「附资质证明」一栏，交稿时那一页却是空的——它根本没经过这一栏。

→检查挡得住已知错误，还要防过早相信「完成」。

这只证明这一类错能被拦住，不证明覆盖了所有风险。

第五章 | 它说完成，还要查什么


文件多了，不等于做完。 语气很满，不等于做完。

文件数量、肯定语气或局部检查通过，都不足以单独证明目标达成。

场景 · 投标书 章节写得满、语气很自信，不等于做完——其实有三条废标项没满足：资质证明、签章页、报价格式。

Anthropic quickstart demo：驱动未按「全部通过」停机。

→先把笼统的「完成」拆成逐条证据。



第一层：清单逐条核查

把笼统的「完成」拆成逐条条件；每条各有证据，才更新对应的完成标记。

前

「已完成」，没有逐条证据。



后

每一条都有对应证据，逐条打勾。

场景 · 投标书 前：「标书已完成」。后：资质证明附上了、签章页盖了、报价格式对了——逐条有证据。

带走 · 验收三层 1/3 拆开

「完成」不是一句话，是一张逐条打勾的清单。

第二层：走完对方的路径

自查清单各有价值，但不能单独证明整件事走得通；还要站到对方的路径上走一遍。

前

自查清单全部打勾，但站到对方的路径上走，有一处走不通。



后

沿着对方的路径从头走一遍，逐条走通、对得上。

场景 · 投标书 评标人打开评分表，有个得分点在标书里找不到对应页。要走：评分表→得分点→标书对应页。

带走 · 验收三层 2/3 走通

别听它说通过，自己走一遍对方的路。

→真实路径通过后，还要保护这条检查本身。

第三层：不能靠削弱检查过关

保住判据才有意义；Agent 应补齐材料，而不是删检查项或跳过核对。

前

为了过关，把检查项删掉。



后

保留检查项，补齐材料，再核对一遍。

场景 · 投标书 为了过关，把「必须附资质证明」这一条删掉；应当保留这一条，补上资质证明，再核对。

带走 · 验收三层 3/3 守住

过关靠把事做对，不靠把标准改低。

人的反馈要能改变下一轮

人的业务信息和纠偏理由，应参与后续行动的决定。

- 纠偏说明依据；拒绝后若继续，理由回到下一轮。
- 人补业务上下文，并负责标准与歧义。

场景 • 投标书 只有你知道这个甲方的采购负责人上次栽在价格评分上、竞争对手已提前接触过——你说明后，它才调整重点。

Andrew Ng • 2026-06-30：人类对用户和产品场景仍有上下文优势。

→就算一切正常停下，停也不等于验收。



Stop ≠ Accepted

超时、资源耗尽或模型收尾，只说明控制流停止；验收要由有权的人依据证据另行签认。

STOP

停止

停止的原因要记录：到上限？没进展？目标门通过？

≠

Accepted

验收

验收要另记：谁验收的，证据在哪。

没有验收证据，就保持「未验收」。

场景 · 投标书 跑到时间上限停了，面板写「初稿已完成」——其实商务部分还空着，没有法务，也没有人签字。

→验收了，就能说业务变好了吗？

产出和业务结果是两本账

检查记录、版本和日志支持产出验收，不自动证明业务变好；采用率、满意度等外部结果，要另设观测与责任人。

产出

可复查的检查记录、版本、日志——验收人签名。

结果

采用率、满意度——上线后才看得见。

看不见时，状态写「待观测」。

场景 · 投标书 标书评审通过、盖章提交了；但「能不能中标」要等开标才知道，先写「待观测」。

→验收和结果分清了，再看一次完整的 /goal 怎么写。

同一个 /goal，三种写法

差别不在写得长不长，而在有没有终态、检查、约束、兜底。

场景 · 投标书

用了，没抓到要领

/goal 把投标书写好

会发生什么：「好」是感觉，没法对照。它写满就说完成，可能漏了硬要求。

抓到要领，手太松

/goal 评分表每一项都有对应页，且不废标

会发生什么：有终态和检查，但没写不许改什么、卡住怎么办。它可能为了达标改规则、删检查，或一直跑下去。

要领在手，手也紧

/goal 评分表逐项有对应页、废标项逐条有证据；不改报价和承诺条款，不删检查；连续两轮没进展就停下交给别人，另设轮数上限

会发生什么：终态、检查、约束、兜底齐全；它说完成只是候选，验收仍由人签。

带走

/goal 不是许愿，是合同。

每一档，人守的责任不同

交出的决定不同，人要守的标准、权限和接手责任也不同；人不是被移出了 Loop。

1

基线

人守什么：你发起、你判断、你接手。

2

动手档

人守什么：你守授权边界。

3

续跑档

人守什么：你守判据、验收和外部结果。

场景 • 投标书 基线：你让它写一章，看完再说下一章。动手档：授权三格——只许起草、只限技术部分、到截止前；改一格就重批。续跑档：/goal 里的终态、检查、约束、兜底由你定；它说完成只是候选，验收你签字。

→那什么时候不要往上爬？

什么时候不要往上爬

完成条件还写不成可观察的句子，就保留人工判断。

1

先别爬

单次小任务

先用脚本，不搭复杂循环。

2

先别爬

品味类目标

先人工标样，别硬跑。

3

先别爬

标准会漂

保留人工检查点，慎用无限循环。

留在低档是按任务作出的控制选择，不是失败。

→走之前，把这六句话带上。

带走这六句话

每一章，记住一句就够了。

第一章

它说完成，凭什么信？

第二章

反馈环要你来搭。

第三章

告示不是门锁。

第四章

把「好」写成能对照的句子。

第五章

拆开、走通、守住。

第六章

/goal 不是许愿，是合同。

→回去，先定档，再动手写。

回去先定档

先写清当前四问的答案，再选择把哪项判断交给系统。

1. 谁启动下一轮？
2. 谁判断完成？
3. 谁能改变系统？
4. 出错时谁能停下接手？

写清当前答案，再选范围；配护栏可翻《循环交接手册》。

拿你团队里一件类似的事试试：方案、报告、投标都行。

定了档，下一步就是写第一份 /goal：终态、检查、约束、兜底，各一句。

